

最优化方法

授课教师：徐海涛

2024年秋

明理，精工，笃学，致远

1

第三章 无约束优化问题

明理，精工，笃学，致远

2

3.6 共轭梯度法

- ◆ **问题：**对于最速下降法，迭代的次数可能会较多
- ◆ 相对于最速下降法，共轭梯度法的性能有了巨大的提升
- ◆ 针对n元二次型函数，共轭梯度法能够通过n次迭代得到极小点，这是最速下降法所不具备的
- ◆ 已经证明，共轭梯度法对于一般形式函数的极小点求解也非常有效

明理，精工，笃学，致远

3

3.6 共轭梯度法

考虑二次型函数的极小化问题：

$$\text{minimize } q(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T \mathbf{A} \mathbf{x} + \mathbf{c}^T \mathbf{x}$$

其中， \mathbf{A} 为对称正定矩阵。满足

$$\mathbf{d}_i^T \mathbf{A} \mathbf{d}_j = 0, \quad i \neq j, \quad 0 \leq i, j \leq n$$

的向量或方向 \mathbf{d}^i 和 \mathbf{d}^j 是关于 \mathbf{A} 共轭的，称为共轭方向。

$$\mathbf{d}_i^T \mathbf{d}_j = 0$$

$$\mathbf{d}_i^T \mathbf{A} \mathbf{d}_j = 0$$

明理，精工，笃学，致远

4

3.6 共轭梯度法 (算法)

共轭方向法首先要求确定初始点 \mathbf{x}_0 和一组共轭方向 $\mathbf{d}_0, \mathbf{d}_1, \dots, \mathbf{d}_{n-1}$ ，沿着方向 \mathbf{d}_0 使得 $q(\mathbf{x})$ 达到最小，从而获得 \mathbf{x}_1 。以此类推，沿着方向 \mathbf{d}_1 使得 $q(\mathbf{x})$ 最小，获得 \mathbf{x}_2 。最后，沿着方向 \mathbf{d}_{n-1} 可获得 \mathbf{x}_n ，这就是函数的极小点 $q(\mathbf{x})$ 。这意味着能够通过 n 次搜索获得二次型函数的极小点。该方法的关键就是如何获得共轭方向，在接下来介绍的算法中，利用 $q(\mathbf{x})$ 的梯度来产生共轭方向。

基本的共轭方向算法。给定初始点 $\mathbf{x}^{(0)}$ 和一组关于 Q 共轭的方向 $\mathbf{d}^{(0)}, \mathbf{d}^{(1)}, \dots, \mathbf{d}^{(n-1)}$ ，迭代公式为 ($k \geq 0$ 表示迭代次数)

$$\begin{aligned} \mathbf{g}^{(k)} &= \nabla f(\mathbf{x}^{(k)}) = Q\mathbf{x}^{(k)} - \mathbf{b} \\ \alpha_k &= -\frac{\mathbf{g}^{(k)\top} \mathbf{d}^{(k)}}{\mathbf{d}^{(k)\top} Q \mathbf{d}^{(k)}} \\ \mathbf{x}^{(k+1)} &= \mathbf{x}^{(k)} + \alpha_k \mathbf{d}^{(k)} \end{aligned}$$

明理，精工，笃学，致远

5

3.6 共轭梯度法 (证明)

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top Q \mathbf{x} - \mathbf{x}^\top \mathbf{b}$$

其中， $Q = Q^\top > 0, \mathbf{x} \in \mathbb{R}^n$ 。注意，由于 $Q > 0$ ，因此函数 f 有一个全局极小点，可通过求解 $Q\mathbf{x} = \mathbf{b}$ 得到。

定理 10.1 对于任意初始点 $\mathbf{x}^{(0)}$ ，基本的共轭方向算法都能在 n 次迭代之内收敛到唯一的全局极小点 \mathbf{x}^* ，即 $\mathbf{x}^{(n)} = \mathbf{x}^*$ 。□

证明：由于方向 $\mathbf{d}^{(i)}, i=0, 1, \dots, n-1$ 线性无关，因此， $\mathbf{x}^* - \mathbf{x}^{(0)} \in \mathbb{R}^n$ 可由它们线性表出，即

$$\mathbf{x}^* - \mathbf{x}^{(0)} = \beta_0 \mathbf{d}^{(0)} + \dots + \beta_{n-1} \mathbf{d}^{(n-1)}$$

其中， $\beta_i, i=0, 1, \dots, n-1$ 为常数。

明理，精工，笃学，致远

6

3.6 共轭梯度法 (证明)

证明：由于方向 $\mathbf{d}^{(i)}, i=0, 1, \dots, n-1$ 线性无关，因此， $\mathbf{x}^* - \mathbf{x}^{(0)} \in \mathbb{R}^n$ 可由它们线性表出，即

$$\mathbf{x}^* - \mathbf{x}^{(0)} = \beta_0 \mathbf{d}^{(0)} + \dots + \beta_{n-1} \mathbf{d}^{(n-1)}$$

其中， $\beta_i, i=0, 1, \dots, n-1$ 为常数。

$$\mathbf{x}^* - \mathbf{x}^{(0)} = \beta_0 \mathbf{d}^{(0)} + \dots + \beta_{n-1} \mathbf{d}^{(n-1)}$$

$$\mathbf{x}^{(n)} - \mathbf{x}^{(0)} = \alpha_0 \mathbf{d}^{(0)} + \dots + \alpha_{n-1} \mathbf{d}^{(n-1)}$$

明理，精工，笃学，致远

7

3.6 共轭梯度法 (证明)

证明：由于方向 $\mathbf{d}^{(i)}, i=0, 1, \dots, n-1$ 线性无关，因此， $\mathbf{x}^* - \mathbf{x}^{(0)} \in \mathbb{R}^n$ 可由它们线性表出，即

$$\mathbf{x}^* - \mathbf{x}^{(0)} = \beta_0 \mathbf{d}^{(0)} + \dots + \beta_{n-1} \mathbf{d}^{(n-1)}$$

其中， $\beta_i, i=0, 1, \dots, n-1$ 为常数。

在等号两端同时左乘 $\mathbf{d}^{(k)\top} Q, 0 \leq k < n$ ，由 Q 共轭的性质可知， $\mathbf{d}^{(k)\top} Q \mathbf{d}^{(i)} = 0, k \neq i$ ，因此有

$$\mathbf{d}^{(k)\top} Q (\mathbf{x}^* - \mathbf{x}^{(0)}) = \beta_k \mathbf{d}^{(k)\top} Q \mathbf{d}^{(k)}$$

整理后，可得

$$\beta_k = \frac{\mathbf{d}^{(k)\top} Q (\mathbf{x}^* - \mathbf{x}^{(0)})}{\mathbf{d}^{(k)\top} Q \mathbf{d}^{(k)}}$$

明理，精工，笃学，致远

8

3.6 共轭梯度法 (证明)

$$\beta_k = \frac{\mathbf{d}^{(k)\top} \mathbf{Q}(\mathbf{x}^* - \mathbf{x}^{(0)})}{\mathbf{d}^{(k)\top} \mathbf{Q} \mathbf{d}^{(k)}}$$

迭代点 $\mathbf{x}^{(k)}$ 可写为

$$\mathbf{x}^{(k)} = \mathbf{x}^{(0)} + \alpha_0 \mathbf{d}^{(0)} + \dots + \alpha_{k-1} \mathbf{d}^{(k-1)}$$

即

$$\mathbf{x}^{(k)} - \mathbf{x}^{(0)} = \alpha_0 \mathbf{d}^{(0)} + \dots + \alpha_{k-1} \mathbf{d}^{(k-1)}$$

而

$$\mathbf{x}^* - \mathbf{x}^{(0)} = (\mathbf{x}^* - \mathbf{x}^{(k)}) + (\mathbf{x}^{(k)} - \mathbf{x}^{(0)})$$

等式两端同时左乘 $\mathbf{d}^{(k)\top} \mathbf{Q}$, 由于 $\mathbf{g}^{(k)} = \mathbf{Q} \mathbf{x}^{(k)} - \mathbf{b}$, $\mathbf{Q} \mathbf{x}^* = \mathbf{b}$, 可得
 $\mathbf{d}^{(k)\top} \mathbf{Q}(\mathbf{x}^* - \mathbf{x}^{(0)}) = \mathbf{d}^{(k)\top} \mathbf{Q}(\mathbf{x}^* - \mathbf{x}^{(k)}) = -\mathbf{d}^{(k)\top} \mathbf{g}^{(k)}$

明理, 精工, 笃学, 致远

9

3.6 共轭梯度法 (证明)

$$\beta_k = \frac{\mathbf{d}^{(k)\top} \mathbf{Q}(\mathbf{x}^* - \mathbf{x}^{(0)})}{\mathbf{d}^{(k)\top} \mathbf{Q} \mathbf{d}^{(k)}}$$

$$\mathbf{d}^{(k)\top} \mathbf{Q}(\mathbf{x}^* - \mathbf{x}^{(0)}) = \mathbf{d}^{(k)\top} \mathbf{Q}(\mathbf{x}^* - \mathbf{x}^{(k)}) = -\mathbf{d}^{(k)\top} \mathbf{g}^{(k)}$$

因此有

$$\beta_k = -\frac{\mathbf{d}^{(k)\top} \mathbf{g}^{(k)}}{\mathbf{d}^{(k)\top} \mathbf{Q} \mathbf{d}^{(k)}} = \alpha_k$$

这说明 $\mathbf{x}^* = \mathbf{x}^{(n)}$, 证明完成。

$$\mathbf{x}^* - \mathbf{x}^{(0)} = \beta_0 \mathbf{d}^{(0)} + \dots + \beta_{n-1} \mathbf{d}^{(n-1)}$$

明理, 精工, 笃学, 致远

10

3.6 共轭梯度法 (根据梯度来获得迭代条件)

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{Q} \mathbf{x} - \mathbf{x}^\top \mathbf{b}$$

基本的共轭方向算法。给定初始点 $\mathbf{x}^{(0)}$ 和一组关于 \mathbf{Q} 共轭的方向 $\mathbf{d}^{(0)}, \mathbf{d}^{(1)}, \dots, \mathbf{d}^{(n-1)}$, 迭代公式为 ($k \geq 0$ 表示迭代次数)

$$\mathbf{g}^{(k)} = \nabla f(\mathbf{x}^{(k)}) = \mathbf{Q} \mathbf{x}^{(k)} - \mathbf{b}$$

$$\alpha_k = -\frac{\mathbf{g}^{(k)\top} \mathbf{d}^{(k)}}{\mathbf{d}^{(k)\top} \mathbf{Q} \mathbf{d}^{(k)}}$$

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{d}^{(k)}$$

明理, 精工, 笃学, 致远

11

3.6 共轭梯度法 (如何获得共轭方向)

考虑二次型函数的极小化问题:

$$\text{minimize } q(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} + \mathbf{c}^\top \mathbf{x}$$

其中, \mathbf{A} 为对称正定矩阵。满足

$$\mathbf{d}_i^\top \mathbf{A} \mathbf{d}_j = 0, \quad i \neq j, \quad 0 \leq i, j \leq n$$

记 $q(\mathbf{x})$ 的梯度为 \mathbf{g} , 则 $\mathbf{g}_k = \nabla q(\mathbf{x}_k) = \mathbf{A} \mathbf{x}_k + \mathbf{c}$ 。点 \mathbf{x}_k 为第 k 次迭代对应的迭代点, 初始点对应的下降方向 \mathbf{d}_0 为最速下降方向, 即 $-\mathbf{g}_0$ 。沿着方向 \mathbf{d}_k 得到函数 $q(\mathbf{x})$ 达到最小, 以此产生新点 \mathbf{x}_{k+1} :

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{d}_k$$

$$\alpha_k = -\frac{\mathbf{d}_k^\top \mathbf{g}_k}{\mathbf{d}_k^\top \mathbf{A} \mathbf{d}_k}$$

明理, 精工, 笃学, 致远

12

3.6 共轭梯度法 (如何获得共轭方向)

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{d}_k \quad \leftarrow \quad \alpha_k = -\frac{\mathbf{d}_k^T \mathbf{g}_k}{\mathbf{d}_k^T \mathbf{A} \mathbf{d}_k}$$

按照微分法则, 由 $dq(\alpha)/d\alpha = 0$ 可推导出 $\mathbf{d}_k^T \mathbf{g}_{k+1} = 0$ $\frac{dq(\alpha)}{d\alpha} = \nabla f(\mathbf{x}_k + \alpha \mathbf{d}_k) \cdot \mathbf{d}_k = \mathbf{g}_{k+1} \cdot \mathbf{d}_k = 0$

接下来就是最关键的步骤了, 按照下式确定下降方向 \mathbf{d}_{k+1} :

$$\mathbf{d}_{k+1} = -\mathbf{g}_{k+1} + \beta_k \mathbf{d}_k$$

上式的含义为对最速下降方向 $-\mathbf{g}_{k+1}$ 进行适当的“纠偏”, 如图 3.6 所示。由于要求 \mathbf{d}_{k+1} 和 \mathbf{d}_k 关于 \mathbf{A} 共轭, 即 $\mathbf{d}_{k+1}^T \mathbf{A} \mathbf{d}_k = 0$ 由此可得

$$-\mathbf{g}_{k+1}^T \mathbf{A} \mathbf{d}_k + \beta_k \mathbf{d}_k^T \mathbf{A} \mathbf{d}_k = 0$$

明理, 精工, 笃学, 致远

13

3.6 共轭梯度法 (如何获得共轭方向)

上式的含义为对最速下降方向 $-\mathbf{g}_{k+1}$ 进行适当的“纠偏”, 如图 3.6 所示。由于要求 \mathbf{d}_{k+1} 和 \mathbf{d}_k 关于 \mathbf{A} 共轭, 即 $\mathbf{d}_{k+1}^T \mathbf{A} \mathbf{d}_k = 0$ 由此可得

$$-\mathbf{g}_{k+1}^T \mathbf{A} \mathbf{d}_k + \beta_k \mathbf{d}_k^T \mathbf{A} \mathbf{d}_k = 0$$

$$\beta_k = \frac{\mathbf{g}_{k+1}^T \mathbf{A} \mathbf{d}_k}{\mathbf{d}_k^T \mathbf{A} \mathbf{d}_k}$$

$$\mathbf{d}_{k+1} = -\mathbf{g}_{k+1} + \beta_k \mathbf{d}_k$$

$$\begin{aligned} \mathbf{g}^{(k)} &= \nabla f(\mathbf{x}^{(k)}) = \mathbf{Q} \mathbf{x}^{(k)} - \mathbf{b} \\ \alpha_k &= -\frac{\mathbf{g}^{(k)T} \mathbf{d}^{(k)}}{\mathbf{d}^{(k)T} \mathbf{Q} \mathbf{d}^{(k)}} \\ \mathbf{x}^{(k+1)} &= \mathbf{x}^{(k)} + \alpha_k \mathbf{d}^{(k)} \end{aligned}$$

明理, 精工, 笃学, 致远

14

3.6 共轭梯度法 (一般性)

对于一般形式函数的极小点求解也非常有效

$$\beta_k = \frac{\mathbf{g}_{k+1}^T \mathbf{A} \mathbf{d}_k}{\mathbf{d}_k^T \mathbf{A} \mathbf{d}_k}$$

由式 (3.20) 可得, $\mathbf{d}_k = (\mathbf{x}_{k+1} - \mathbf{x}_k)/\alpha_k$, 因此, $\mathbf{A} \mathbf{d}_k = (\mathbf{g}_{k+1} - \mathbf{g}_k)/\alpha_k$, 代入上式并整理后可得

$$\beta_k = \frac{\mathbf{g}_{k+1}^T (\mathbf{g}_{k+1} - \mathbf{g}_k)}{\alpha_k \mathbf{d}_k^T \mathbf{A} \mathbf{d}_k}$$

明理, 精工, 笃学, 致远

15

3.6 共轭梯度法 (一般性)

$$\beta_k = \frac{\mathbf{g}_{k+1}^T (\mathbf{g}_{k+1} - \mathbf{g}_k)}{\alpha_k \mathbf{d}_k^T \mathbf{A} \mathbf{d}_k} \quad \alpha_k = \frac{-\mathbf{d}_k^T \mathbf{g}_k}{\mathbf{d}_k^T \mathbf{A} \mathbf{d}_k}$$

$$\mathbf{d}_k^T \mathbf{g}_{k+1} = 0 \quad \rightarrow \quad \mathbf{d}_{k+1}^T \mathbf{g}_{k+1} = -\mathbf{g}_{k+1}^T \mathbf{g}_{k+1} + \beta_k \mathbf{d}_k^T \mathbf{g}_{k+1}$$

明理, 精工, 笃学, 致远

16

3.6 共轭梯度法 (一般性)

$$d_k^T g_{k+1} = 0$$

$$d_{k+1} = -g_{k+1} + \beta_k d_k \quad \Rightarrow \quad d_{k+1}^T g_{k+1} = -g_{k+1}^T g_{k+1} + \beta_k d_k^T g_{k+1}$$

$$d_{k+1}^T g_{k+1} = -g_{k+1}^T g_{k+1} \quad d_k^T g_k = -g_k^T g_k$$

$$\alpha_k = \frac{-d_k^T g_k}{d_k^T A d_k} \quad \Rightarrow \quad \alpha_k = \frac{g_k^T g_k}{d_k^T A d_k}$$

明理，精工，笃学，致远

17

3.6 共轭梯度法 (一般性)

$$\alpha_k = \frac{g_k^T g_k}{d_k^T A d_k} \quad \Rightarrow \quad \beta_k = \frac{g_{k+1}^T (g_{k+1} - g_k)}{\alpha_k d_k^T A d_k}$$

$$\beta_k = \frac{g_{k+1}^T (g_{k+1} - g_k)}{g_k^T g_k}$$

由式 (3.32) 可以看出, β_k 与矩阵 A 和向量 c 无关, 这意味着该算法也适用于非二次型函数的极小点求解问题。但是, 对于非二次型函数, 式 (3.31) 所示的步长公式就不再适用了, 必须采用数值线性搜索方法来求解步长 α_k 。当然, 通过 n 步迭代就可以得到最优解这一特性只适用于二次型函数。对于非二次型函数, 应该每 n 次迭代完成之后, 都需要将下降方向重置为当前梯度的负方向, 即最速下降方向。采用式 (3.32) 来计算 β_k 的共轭梯度法称为 Polak - Ribiere 算法。

明理，精工，笃学，致远

18

3.6 共轭梯度法 (一般性)

$$\beta_k = \frac{g_{k+1}^T (g_{k+1} - g_k)}{g_k^T g_k} \quad \Rightarrow \quad \beta_k = \frac{g_{k+1}^T g_{k+1}}{g_k^T g_k}$$

$$g_{k+1}^T g_k = g_{k+1}^T (-d_k + \beta_{k-1} d_{k-1}) = \beta_{k-1} g_{k+1}^T d_{k-1} \quad A d_k = (g_{k+1} - g_k) / \alpha_k$$

$$= \beta_{k-1} (g_k^T + \alpha_k d_k^T A) d_{k-1}$$

$$= 0$$

这称为 Fletcher-Reeves 算法 [Fletcher and Reeves, 1964]

明理，精工，笃学，致远

19

3.6 共轭梯度法 (例题)

例 3.9 函数为 $f = x_1^2 + 4x_2^2$, 初始点为 $x_0 = [1, 1]^T$ 。利用共轭梯度法开展两次迭代, 即可得到极小点。第一次迭代对应的下降方向为最速下降方向, 即

$$d_0 = -\nabla f(x_0) = -[2, 8]^T$$

此处未将方向向量进行归一化处理, 不影响后续计算。求函数

$$f(\alpha) = f(x_0 + \alpha d_0) = (1 - 2\alpha)^2 + 4(1 - 8\alpha)^2$$

的极小点, 可得 $\alpha_0 = 0.1307692$, 构造新点为 $x_1 = x_0 + \alpha_0 d_0 = [0.7384615, -0.0461538]^T$ 。进入到下一次迭代, 计算

$$\beta_0 = \frac{\|\nabla f(x_1)\|^2}{\|\nabla f(x_0)\|^2} = 2.3176/68 = 0.0340828$$

$$d_1 = -\nabla f(x_1) + \beta_0 d_0 = \begin{pmatrix} -1.476923 \\ 0.369231 \end{pmatrix} + 0.0340828 \begin{pmatrix} -2 \\ -8 \end{pmatrix} = \begin{pmatrix} -1.54508 \\ 0.09656 \end{pmatrix}$$

明理，精工，笃学，致远

20



3.6 共轭梯度法 (例题)

求函数

$$f(\alpha) = f(\mathbf{x}_1 + \alpha \mathbf{d}_1) = (0.738\ 461\ 5 - 1.545\ 08\alpha)^2 + 4(-0.046\ 153\ 8 + 0.096\ 56\alpha)^2$$

的极小点, 得到步长和下一个迭代点为

$$\alpha_1 = 0.477\ 941$$

$$\mathbf{x}_2 = \mathbf{x}_1 + \alpha_1 \mathbf{d}_1 = \begin{pmatrix} 0.738\ 461\ 5 \\ -0.046\ 153\ 8 \end{pmatrix} + 0.477\ 941 \begin{pmatrix} -1.545\ 08 \\ 0.096\ 56 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

这验证了前面的结论, 即经过 $n=2$ 次迭代之后, 算法收敛于极小点。

明理, 精工, 笃学, 致远

21

本节结束, 谢谢

Thank you for listening

课程名称: 最优化方法

明理, 精工, 笃学, 致远



习题

作业题: P3.1 P3.3 P3.4 P3.10

思考题: P3.5 P3.6

明理, 精工, 笃学, 致远

23