

明理精工

笃学致远

第6章 生成式分类器

GenClassifier



电子工程学院、人工智能学院

college of Electronic Engineering , college of Artificial Intelligence

■生成式分类器

■朴素贝叶斯分类器

1. 生成式分类器 vs. 判别式分类器

- **生成式分类器**: 对所有变量的分布建模 $p(\mathbf{x}, y)$
 - 得到类先验概率 $p(y)$, 类条件概率 $p(\mathbf{x}|y)$
 - 根据贝叶斯公式, 得到后验, 实现分类
 - 知道所有变量的分布, 可以产生数据
- **判别式分类器**: 直接对后验概率 $p(y|\mathbf{x})$ 建模, 或者直接对判别边界建模 $f(\mathbf{x})$
 - Logistic回归: 对后验概率 $p(y|\mathbf{x})$ 建模
 - SVM: 直接对判别函数 $f(\mathbf{x})$ 建模

➤ 贝叶斯公式

生成式分类器对所有变量的分布建模 $p(\mathbf{x}, y) = p(y) p(\mathbf{x}|y)$

根据贝叶斯公式，得到后验，实现分类：

$$p(y = c|\mathbf{x}) = \frac{p(\mathbf{x}, y)}{\sum_{c'} p(\mathbf{x})} = \frac{p(\mathbf{x}|y=c)p(y=c)}{\sum_{c'} p(\mathbf{x}|y=c')p(y=c')} \propto \underbrace{p(\mathbf{x}|y = c)}_{\text{类条件概率}} \underbrace{p(y = c)}_{\text{类先验概率}}$$

类先验概率可用多项分布表示： $y \sim \text{Multinoulli}(\boldsymbol{\theta})$

类条件概率 $p(\mathbf{x}|y)$ ：由于 \mathbf{x} 为多维向量，条件分布 $p(\mathbf{x}|y)$ 建模困难，对其做适当假设

- 朴素贝叶斯：在给定 y 的情况下， \mathbf{x} 的各维独立
- 高斯判别分析：在给定 y 的情况下， \mathbf{x} 为多元高斯分布

2. 朴素贝叶斯分类器 (Naive Bayes Classifier, NBC)

■ 假设共有 C 个类别 $y \in \{1, 2, \dots, C\}$, 类别的先验分布

- 两类: $y \sim \text{Bernoulli}(\theta)$

- 多类: $y \sim \text{Multinoulli}(\boldsymbol{\theta})$

$$\text{Multinoulli}(\boldsymbol{\theta}) = \prod_{c=1}^C \theta_c^{\mathbb{I}(y_i=c)}$$

■ 每个样本的特征为: $\boldsymbol{x} = (x_1, x_2, \dots, x_D)^T$

■ 朴素贝叶斯分类器假设各维特征在给定类别标签的情况下**条件独立**

$$p(\boldsymbol{x}|y = c) = \prod_{j=1}^D p(x_j|y = c)$$

➤ 朴素贝叶斯的训练（模型参数估计）

log似然函数为

$$\begin{aligned}\ln p(\mathcal{D}) &= \sum_{i=1}^N \ln p(\mathbf{x}_i, y_i) = \sum_{i=1}^N \ln(p(\mathbf{x}_i|y_i)p(y_i)) = \sum_{i=1}^N \ln p(\mathbf{x}_i|y_i) + \sum_{i=1}^N \ln p(y_i) \\ &= \sum_{i=1}^N \ln \left(\prod_{c=1}^C (p(\mathbf{x}_i|y_i = c))^{\mathbb{I}(y_i=c)} \right) + \sum_{i=1}^N \ln \left(\prod_{c=1}^C \theta_c^{\mathbb{I}(y_i=c)} \right) \\ &= \sum_{i=1}^N \ln \left(\prod_{c=1}^C \left(\prod_{j=1}^D p(x_{ij}|y_i = c) \right)^{\mathbb{I}(y_i=c)} \right) + \sum_{i=1}^N \ln \left(\prod_{c=1}^C \theta_c^{\mathbb{I}(y_i=c)} \right) \\ &= \sum_{i=1}^N \sum_{c=1}^C \mathbb{I}(y_i = c) \sum_{j=1}^D \ln p(x_{ij}|y_i = c) + \sum_{i=1}^N \sum_{c=1}^C \ln \theta_c^{\mathbb{I}(y_i=c)}\end{aligned}$$

类条件概率 类先验概率

log似然函数:

$$\ln p(\mathcal{D}) = \sum_{i=1}^N \sum_{c=1}^C \sum_{j=1}^D \mathbb{I}(y_i = c) \ln p(x_{ij} | y_i = c) + \sum_{i=1}^N \sum_{c=1}^C \ln \theta_c^{\mathbb{I}(y_i=c)}$$

✓ 类先验概率

求参数 θ_c , 需约束条件: $\sum_{c=1}^C \theta_c = 1$

采用拉格朗日乘子法求极值:

$$J(\lambda, \boldsymbol{\theta}) = \sum_{i=1}^N \sum_{c=1}^C \mathbb{I}(y_i = c) \ln(\theta_c) + \lambda(1 - \sum_{c=1}^C \theta_c)$$

$$\frac{\partial J(\lambda, \boldsymbol{\theta})}{\partial \theta_c} = \frac{1}{\theta_c} \sum_{i=1}^N \sum_{c=1}^C \mathbb{I}(y_i = c) - \lambda = 0$$

$$\frac{\partial J(\lambda, \boldsymbol{\theta})}{\partial \lambda} = 1 - \sum_{c=1}^C \theta_c = 0$$

第 c 类的样本占有所有样本的比例

$$\theta_c = \frac{\sum_{i=1}^N \sum_{c=1}^C \mathbb{I}(y_i = c)}{N} = \frac{N_c}{N}$$

✓ 类条件概率

类条件概率

$$\ln p(\mathcal{D}) = \sum_{i=1}^N \sum_{c=1}^C \sum_{j=1}^D \mathbb{I}(y_i = c) \ln p(x_{ij} | y_i = c) + \sum_{i=1}^N \sum_{c=1}^C \ln \theta_c^{\mathbb{I}(y_i=c)}$$

(1) 伯努利分布——NBC二值特征

$p(x_j | Y = c)$ 可用伯努利分布 **Bernoulli**($x_j | Y = c, \theta_{c,j}$) 表示,

其中参数 $\theta_{c,j}$ 表示在类别 $Y = c$ 的情况下, 特征 $X_j = 1$ 的概率。

$$p(x_{i,j} | y_i = c) = (\theta_{c,j})^{x_{i,j}} (1 - \theta_{c,j})^{1-x_{i,j}}$$



$$p(x_{i,j}|y_i = c) = (\theta_{c,j})^{x_{i,j}}(1 - \theta_{c,j})^{1-x_{i,j}}$$

- log似然函数为

$$\begin{aligned}\ln p(\mathcal{D}) &= \sum_{i=1}^N \sum_{c=1}^C \mathbb{I}(y_i = c) \sum_{j=1}^D \ln p(x_{i,j}|y_i = c) + \sum_{i=1}^N \sum_{c=1}^C \ln \theta_c \\&= \sum_{i=1}^N \sum_{c=1}^C \mathbb{I}(y_i = c) \sum_{j=1}^D \ln \left((\theta_{c,j})^{x_{i,j}} (1 - \theta_{c,j})^{1-x_{i,j}} \right) + \sum_{i=1}^N \sum_{c=1}^C \ln \theta_c \\&= \sum_{i=1}^N \sum_{c=1}^C \sum_{j=1}^D \mathbb{I}(y_i = c) (x_{i,j} \ln \theta_{c,j} + (1 - x_{i,j}) \ln(1 - \theta_{c,j})) + \sum_{i=1}^N \sum_{c=1}^C \ln \theta_c\end{aligned}$$

- 类条件分布的参数 $\theta_{c,j}$ 与似然函数中第一项有关

$$\frac{\partial \ln p(\mathcal{D})}{\partial \theta_{c,j}} = \sum_{i=1}^N \sum_{c=1}^C \mathbb{I}(y_i = c) \frac{x_{i,j}}{\theta_{c,j}} - \sum_{i=1}^N \sum_{c=1}^C \mathbb{I}(y_i = c) \frac{1 - x_{i,j}}{1 - \theta_{c,j}}$$

- log似然函数对参数 $\theta_{c,j}$ 的一阶偏导数为0:

$$\frac{\partial \ln p(\mathcal{D})}{\partial p_{c,j}} = \sum_{i=1}^N \sum_{c=1}^C \mathbb{I}(y_i = c) \frac{x_{i,j}}{\theta_{c,j}} - \sum_{i=1}^N \sum_{c=1}^C \mathbb{I}(y_i = c) \frac{1 - x_{i,j}}{1 - \theta_{c,j}} = 0$$

$$\sum_{i=1}^N \sum_{c=1}^C \mathbb{I}(y_i = c) x_{i,j} (1 - \theta_{c,j}) = \sum_{i=1}^N \sum_{c=1}^C \mathbb{I}(y_i = c) (1 - x_{i,j}) \theta_{c,j}$$

$$\sum_{i=1}^N \sum_{c=1}^C \mathbb{I}(y_i = c) x_{i,j} = \sum_{i=1}^N \sum_{c=1}^C \mathbb{I}(y_i = c) \theta_{c,j}$$

$$\hat{\theta}_{c,j} = \frac{\sum_{i=1}^N \sum_{c=1}^C \mathbb{I}(y_i = c) x_{i,j}}{\sum_{i=1}^N \sum_{c=1}^C \mathbb{I}(y_i = c)} = \frac{N_{c,j}}{N_c}$$

$\frac{\text{Y=c, X}_j=1\text{的样本数目}}{\text{第}c\text{类的样本数目}}$

$$\hat{\theta}_{c,j} = \frac{\sum_{i=1}^N \sum_{c=1}^C \mathbb{I}(y_i = c) x_{i,j}}{\sum_{i=1}^N \sum_{c=1}^C \mathbb{I}(y_i = c)} = \frac{N_{c,j}}{N_c}$$



当观测 $N_{c,j} = 0$ 时, $\hat{\theta}_{c,j} = 0$, 从而

$$p(x_{i,j} | y_i = c) = (\hat{\theta}_{c,j})^{x_{i,j}} (1 - \hat{\theta}_{c,j})^{1-x_{i,j}} = 0$$

$$p(\mathbf{x} | y = c) = \prod_{j=1}^D p(x_j | y = c) = 0$$

$$p(y = c | \mathbf{x}) \propto p(\mathbf{x} | y = c) p(y = c) = 0$$



解决方案: 类条件平滑 (加入伪计数, 每个特征取值的样本数增加 平滑因子 α)

$$\hat{\theta}_{c,j} = \frac{N_{c,j} + \alpha}{N_c + 2\alpha}$$

$\alpha = 1$: 拉普拉斯平滑

	text	information	identifying	mining	mined	is	useful	to	from	apple	delicious	Y
D1	1	1	1	1	0	1	1	1	0	0	0	1
D2	1	1	0	0	1	1	1	0	1	0	0	1
D3	0	0	0	0	0	1	0	0	0	1	1	0

朴素贝叶斯大大减少了模型的参数量

- 无独立假设:

$$p(y = c | \mathbf{x}) = p(\mathbf{x} | y) p(y)$$

V 个二值特征

类条件密度参数: $C \times (2^V - 1)$

类先验参数: $C - 1$


- 条件独立假设:

$$p(y = c | \mathbf{x}) = p(\mathbf{x} | y) p(y)$$

$$= \prod_{j=1}^D p(x_j | y) p(y)$$

类条件密度参数: $C \times V$

类先验参数: $C - 1$



(2) Multinomial分布——NBC离散型特征（类别型特征）

假设特征有 M 种取值, $p(x_j|Y = c)$ 可用类别分布 $\text{Cat}(x_j|Y = c, \theta_{c,j,m})$ 表示, 其中参数 $\theta_{c,j,m}$ 表示在类别 $Y = c$ 的情况下, 特征 $X_j = m$ 的概率。

$$p(x_{i,j} = m|y_i = c) = \prod_{m=1}^M (\theta_{c,j,m})^{\mathbb{I}(x_{i,j}=m)}$$

$$p(x_{i,j} = m | y_i = c) = \prod_{m=1}^M (\theta_{c,j,m})^{\mathbb{I}(x_{i,j}=m)}$$

- log似然函数为

$$\begin{aligned} \ln p(\mathcal{D}) &= \sum_{i=1}^N \sum_{c=1}^C \mathbb{I}(y_i = c) \sum_{j=1}^D \ln p(x_{ij} | y_i = c) + \sum_{i=1}^N \sum_{c=1}^C \ln \theta_c \\ &= \sum_{i=1}^N \sum_{c=1}^C \mathbb{I}(y_i = c) \sum_{j=1}^D \ln \left(\prod_{m=1}^M (\theta_{c,j,m})^{\mathbb{I}(x_{i,j}=m)} \right) + \sum_{i=1}^N \sum_{c=1}^C \ln \theta_c \\ &= \sum_{i=1}^N \sum_{c=1}^C \sum_{j=1}^D \sum_{m=1}^M \mathbb{I}(y_i = c) \mathbb{I}(x_{i,j} = m) \ln \theta_{c,j,m} + \sum_{i=1}^N \sum_{c=1}^C \ln \theta_c \end{aligned}$$

- 类条件分布的参数 $\theta_{c,j,m}$ 与似然函数中第一项有关

$$\frac{\partial \ln p(\mathcal{D})}{\partial \theta_{c,j,m}} = \sum_{i=1}^N \sum_{c=1}^C \sum_{m=1}^M \mathbb{I}(y_i = c) \frac{\mathbb{I}(x_{i,j} = m)}{\theta_{c,j,m}}$$

- 需约束条件： $\sum_{m=1}^M \theta_{j,c,m} = 1$ ，采用拉格朗日乘子法求 $\theta_{c,j,m}$ 的值：

$$J(\lambda, \boldsymbol{\theta}) = \sum_{i=1}^N \sum_{c=1}^C \sum_{j=1}^D \sum_{m=1}^M \mathbb{I}(y_i = c) \mathbb{I}(x_{i,j} = m) \ln \theta_{c,j,m} + \lambda (1 - \sum_{m=1}^M \theta_{c,j,m})$$


$$\frac{\partial J(\lambda, \boldsymbol{\theta})}{\partial \theta_{c,j,m}} = \sum_{i=1}^N \sum_{c=1}^C \sum_{m=1}^M \mathbb{I}(y_i = c) \frac{\mathbb{I}(x_{i,j} = m)}{\theta_{c,j,m}} - \lambda = 0$$

$$\frac{\partial J(\lambda, \boldsymbol{\theta})}{\partial \lambda} = 1 - \sum_{m=1}^M \theta_{c,j,m} = 0$$

$$\hat{\theta}_{c,j,m} = \frac{\sum_{i=1}^N \sum_{c=1}^C \sum_{m=1}^M \mathbb{I}(y_i = c) \mathbb{I}(x_{i,j} = m)}{\sum_{i=1}^N \sum_{c=1}^C \mathbb{I}(y_i = c)} = \frac{N_{c,j,m}}{N_c}$$

第 c 类的所有样本，第 j 维特征值为 m 的样本数目
第 c 类的样本数目

$$\hat{\theta}_{c,j,m} = \frac{N_{c,j,m} + \alpha}{N_c + M_j \alpha}$$



(3) 多项分布

- 特征取值为**序数**（如出现次数），第 v 维特征表示字典第 v 个单词出现的次数

$$\hat{\theta}_{c,v} = \frac{N_{c,v}}{N_c}$$


第 c 类的所有样本/文档中，第 v 个单词出现的次数和
第 c 类文档中的总单词数目

Sklearn中的实现: [MultinomialNB](#)

(4) 高斯分布——NBC连续特征

$$p(x_{i,j}|y_i = c) = N(\mu_{c,j}, \sigma_{c,j}) = \frac{1}{\sqrt{2\pi}\sigma_{c,j}} e^{-\frac{(x_{i,j}-\mu_{c,j})^2}{2(\sigma_{c,j})^2}}$$

Sklearn中的实现: [GaussianNB](#)



- 采用极大似然法来估计模型参数，log似然函数为

$$p(x_{i,j}|y_i = c) = \frac{1}{\sqrt{2\pi}\sigma_{c,j}} e^{-\frac{(x_{i,j}-\mu_{c,j})^2}{2(\sigma_{c,j})^2}}$$

$$\begin{aligned}\ln p(\mathcal{D}) &= \sum_{i=1}^N \sum_{c=1}^C \mathbb{I}(y_i = c) \sum_{j=1}^D \ln p(x_{ij}|y_i = c) + \sum_{i=1}^N \sum_{c=1}^C \ln \theta_c \\ &= \sum_{i=1}^N \sum_{c=1}^C \mathbb{I}(y_i = c) \sum_{j=1}^D \ln \left(\frac{1}{\sqrt{2\pi}\sigma_{c,j}} e^{-\frac{(x_{i,j}-\mu_{c,j})^2}{2\sigma^2}} \right) + \sum_{i=1}^N \sum_{c=1}^C \ln \theta_c \\ &= - \sum_{i=1}^N \sum_{c=1}^C \mathbb{I}(y_i = c) \frac{D}{2} \ln(2\pi) - \sum_{i=1}^N \sum_{c=1}^C \mathbb{I}(y_i = c) D \ln(\sigma_{c,j}) \\ &\quad - \sum_{i=1}^N \sum_{c=1}^C \mathbb{I}(y_i = c) \sum_{j=1}^D \frac{(x_{i,j} - \mu_{c,j})^2}{2(\sigma_{c,j})^2} + \sum_{i=1}^N \sum_{c=1}^C \ln \theta_c\end{aligned}$$

- 类条件分布的参数 $\mu_{j,c}$, $\sigma_{j,c}$ 与似然函数中第2项和第3项有关

- 似然函数对参数求偏导数:

$$\ln p(\mathcal{D}) = -\sum_{i=1}^N \sum_{c=1}^C \mathbb{I}(y_i = c) D \ln(\sigma_{c,j}) - \sum_{i=1}^N \sum_{c=1}^C \mathbb{I}(y_i = c) \sum_{j=1}^D \frac{(x_{i,j} - \mu_{c,j})^2}{2(\sigma_{j,c})^2}$$

$$\frac{\ln p(\mathcal{D})}{\partial \mu_{c,j}} = \frac{1}{(\sigma_{j,c})^2} \sum_{i=1}^N \sum_{c=1}^C \mathbb{I}(y_i = c) (x_{i,j} - \mu_{c,j}) = 0$$

$$\hat{\mu}_{c,j} = \frac{\sum_{i=1}^N \sum_{c=1}^C \mathbb{I}(y_i=c) x_{i,j}}{\sum_{i=1}^N \sum_{c=1}^C \mathbb{I}(y_i=c)} = \bar{x}_{i,j}$$

第 c 类的所有样本，第 j 维特征值的均值

- 似然函数对参数求偏导数:

$$\ln p(\mathcal{D}) = -\sum_{i=1}^N \sum_{c=1}^C \mathbb{I}(y_i = c) D \ln(\sigma_{c,j}) - \sum_{i=1}^N \sum_{c=1}^C \mathbb{I}(y_i = c) \sum_{j=1}^D \frac{(x_{i,j} - \mu_{j,c})^2}{2(\sigma_{c,j})^2}$$

$$\frac{\ln p(\mathcal{D})}{\partial \sigma_{c,j}} = -\frac{1}{\sigma_{c,j}} \sum_{i=1}^N \sum_{c=1}^C \mathbb{I}(y_i = c) + \sum_{i=1}^N \sum_{c=1}^C \mathbb{I}(y_i = c) \frac{(x_{i,j} - \mu_{j,c})^2}{(\sigma_{c,j})^3} = 0$$

$$(\sigma_{c,j})^2 = \frac{\sum_{i=1}^N \sum_{c=1}^C \mathbb{I}(y_i=c) (x_{i,j} - \mu_{j,c})^2}{\sum_{i=1}^N \sum_{c=1}^C \mathbb{I}(y_i=c)} \quad (5-10)$$

第 c 类的所有样本,
第 j 维特征值的样本方差

例：SNS账号真实性判断 $X=[m,m,yes]$?

1. 类先验概率:

$$\bar{\theta}_0 = P(R = \text{yes}) = \frac{7}{10}$$

$$\bar{\theta}_1 = P(R = \text{no}) = \frac{3}{10}$$

2. 类条件概率:

日志密度 L	好友密度 F	是否使用真实头像 H	账号是否真实 R
s	s	no	no
s	l	yes	yes
l	m	yes	yes
m	m	yes	yes
l	m	yes	yes
m	l	no	yes
m	s	no	no
l	m	no	yes
m	s	no	yes
s	s	yes	no

当类别 $R = \text{yes}$ 时，共有 $N_0 = 7$ 个样本，

特征日志密度 L 有3种取值：s, l, m，样本数分别为：1, 3, 3，再加入平滑计数 $\alpha = 1$ ，得到

$$\hat{\theta}_{0,0,s} = \frac{1+1}{7+3} = \frac{1}{5} \quad \hat{\theta}_{0,0,l} = \frac{2}{5} \quad \hat{\theta}_{0,0,m} = \frac{2}{5}$$

类似地，得到其他 2 维特征 F 、 H 的类条件分布的参数为

$$\bar{\theta}_{0,F,s} = \frac{1+1}{3+7} = \frac{1}{5}, \quad \bar{\theta}_{0,F,m} = \frac{1+2}{3+7} = \frac{3}{10}, \quad \bar{\theta}_{0,F,l} = \frac{1+4}{3+7} = \frac{1}{2},$$

$$\bar{\theta}_{0,H,no} = \frac{1+3}{2+7} = \frac{4}{9}, \quad \bar{\theta}_{0,H,yes} = \frac{1+4}{2+7} = \frac{5}{9}.$$

② 当类别标签 $R = no$ 时， $N_1 = 3$ ，特征日志密度 L 有 s, m, l 这 3 种取值，用 Multinoulli 分布建模， $M_0 = 3$ 。在 $R = no$ 的 3 个样本中，上述 3 种特征取值的样本数分别为 2、1、0，即

$$N_{1,L,s} = 2, \quad N_{1,L,m} = 1, \quad N_{1,L,l} = 0,$$

根据式（5-8），得到

$$\bar{\theta}_{1,L,s} = \frac{1+2}{3+3} = \frac{1}{2}, \quad \bar{\theta}_{1,L,m} = \frac{1+1}{3+3} = \frac{1}{3}, \quad \bar{\theta}_{1,L,l} = \frac{1+0}{3+3} = \frac{1}{6}.$$

类似地，得到其他 2 维特征 F 、 H 的类条件分布的参数为

$$\bar{\theta}_{1,F,s} = \frac{1+3}{3+3} = \frac{2}{3}, \quad \bar{\theta}_{1,F,m} = \frac{1+0}{3+3} = \frac{1}{6}, \quad \bar{\theta}_{1,F,l} = \frac{1+0}{3+3} = \frac{1}{6},$$

$$\bar{\theta}_{1,H,no} = \frac{1+1}{2+3} = \frac{2}{5}, \quad \bar{\theta}_{1,H,yes} = \frac{1+2}{2+3} = \frac{3}{5}.$$


3. 预测新样本 $X=[m,m,\text{yes}]$

$$\begin{aligned} & P(R = \text{yes} | L = m, F = m, H = \text{yes}) \\ & \propto P(L = m | R = \text{yes}) P(F = m | R = \text{yes}) P(H = \text{yes} | R = \text{yes}) P(R = \text{yes}) \\ & = \bar{\theta}_{0,L,m} \times \bar{\theta}_{0,F,m} \times \bar{\theta}_{0,H,\text{yes}} \times \bar{\theta}_0 = \frac{2}{5} \times \frac{3}{10} \times \frac{5}{9} \times \frac{2}{3} = \frac{4}{90}, \end{aligned}$$

$$\begin{aligned} & P(R = \text{no} | L = m, F = m, H = \text{yes}) \\ & \propto P(L = m | R = \text{no}) P(F = m | R = \text{no}) P(H = \text{yes} | R = \text{no}) P(R = \text{no}) \\ & = \bar{\theta}_{1,L,m} \times \bar{\theta}_{1,F,m} \times \bar{\theta}_{1,H,\text{yes}} \times \bar{\theta}_1 = \frac{1}{3} \times \frac{1}{6} \times \frac{3}{5} \times \frac{1}{3} = \frac{1}{90}, \end{aligned}$$

$$P(R = \text{yes} | L = m, F = m, H = \text{yes}) > P(R = \text{no} | L = m, F = m, H = \text{yes}),$$

因此该用户的账号真实的可能性更高。



➤ Sklearn中的朴素贝叶斯实现

Scikit-Learn中提供5种朴素贝叶斯的分类算法：

- GaussianNB：特征值为连续值且为高斯分布
- BernoulliNB：特征值为二值
- CategoricalNB：特征值为多个离散值
- MultinomialNB：特征值为多个序数值
- ComplementNB：MultinomialNB 的一种改进，特别适用于不平衡数据集。
ComplementNB使用来自每个类的补数的统计数据来计算模型的权重，这样参数估计更稳定，在文本分类任务上，性能通常更好

朴素贝叶斯分类器

$$p(y = c|x) = p(x|y = c)p(y = c)$$

✓ 类先验概率 $p(y = c) = \frac{N_c}{N}$

✓ 类条件概率 $p(x|y = c)$

- 伯努利分布 $\hat{\theta}_{c,j} = \frac{N_{c,j} + \alpha}{N_c + 2\alpha}$
- Multinomial分布 $\hat{\theta}_{c,j,m} = \frac{N_{c,j,m} + \alpha}{N_c + M_j\alpha}$
- 多项式分布
- 高斯分布